

HW_1

FLOPs | Будем считать MAC на слоях используя отношение

$$1 \text{ MAC} = 2 \text{ FLOPs}$$

ReLU и Max-pooling исключены из расчета FLOPs, (т.к. там операции сравнения, а не сложения/умножения), но будут учтены в расчете bytes-moved.

Посчитаем для GlobalAvgPooling будем считать отдельно.

$$\text{Output_size} = \left\lfloor \frac{S + 2 \cdot P - k}{\text{Str}} + 1 \right\rfloor; \quad \text{FLOPs}_{\text{conv}} = 2 \cdot \text{MAC}_S = 2 \cdot B \times k^2 \times C_{\text{in}} \times C_{\text{out}} \times S_{\text{out}}^2$$

1) conv1: $S_{\text{out}} = \left\lfloor \frac{S + 6 - 7}{2} + 1 \right\rfloor = \left\lfloor \frac{S - 1 + 2}{2} \right\rfloor = \frac{S}{2}$

$\text{FLOPs} = 2 \cdot B \cdot 49 \cdot 3 \cdot 32 \cdot \left(\frac{S}{2}\right)^2 = 2352 B S^2$

B - batch, k - kernel size, C_{in} - число входных каналов
 C_{out} - число выходных каналов
 S_{out}^2 - разрешение на выходе

2) MaxPool: $S_{\text{out}} = \left\lfloor \frac{\frac{S}{2} + 2 \cdot 2 - 3}{2} + 1 \right\rfloor = \left\lfloor \frac{\frac{S}{2} + 2}{2} \right\rfloor = \frac{S}{4}$

3) conv2: $S_{\text{out}} = \left\lfloor \frac{\frac{S}{4} + 4 - 5}{1} + 1 \right\rfloor = \frac{S}{4}$

$\text{FLOPs} = 2 \cdot B \cdot 25 \cdot 32 \cdot 64 \cdot \left(\frac{S}{4}\right)^2 = 6400 B S^2$

4) conv3: $S_{\text{out}} = \left\lfloor \frac{\frac{S}{4} + 2 - 3}{2} + 1 \right\rfloor = \left\lfloor \frac{\frac{S}{4} + 1}{2} \right\rfloor = \frac{S}{8}$

$\text{FLOPs} = 2 \cdot B \cdot 9 \cdot 64 \cdot 128 \cdot \left(\frac{S}{8}\right)^2 = 2304 B S^2$

5) conv4: $S_{\text{out}} = \left\lfloor \frac{\frac{S}{8} + 0 - 1}{1} + 1 \right\rfloor = \frac{S}{8}$ $\text{FLOPs} = 2 \cdot B \cdot 1 \cdot 128 \cdot 256 \cdot \left(\frac{S}{8}\right)^2 = 1024 B S^2$

6) conv5: $S_{\text{out}} = \left\lfloor \frac{\frac{S}{8} + 2 - 3}{2} + 1 \right\rfloor = \left\lfloor \frac{\frac{S}{8} + 1}{2} \right\rfloor = \frac{S}{16}$ $\text{FLOPs} = 2 \cdot B \cdot 9 \cdot 256 \cdot 512 \cdot \frac{S^2}{16^2} = 4608 B S^2$

7) conv6: $S_{\text{out}} = \left\lfloor \frac{\frac{S}{16} - 1}{1} + 1 \right\rfloor = \frac{S}{16}$ $\text{FLOPs} = 2 \cdot B \cdot 1 \cdot 256 \cdot 512 \cdot \frac{S^2}{16^2} = 1024 B S^2$

8) Global Avg Pool: Состав из 5-5-1 соединений и 1 элемент на каждый канал

$$\text{Known FLOPs} = 2 \cdot B \cdot C \cdot S \cdot S = 2 \cdot B \cdot 512 \cdot \left(\frac{S^2}{16}\right) = 4B \cdot S^2$$

9) FC1: $\text{FLOPs} = 2 \cdot B \cdot I_n \cdot \text{Out} = 2 \cdot B \cdot 512 \cdot 256 = 262\,144\,B$

10) FC2: $\text{FLOPs} = 2 \cdot B \cdot 256 \cdot 100 = 51200\,B$

Unknown: $\text{Total FLOPs} = BS^2(2352 + 6400 + 2304 + 1024 + 4608 + 1024) + 313\,344\,B =$
 $= \underline{\underline{17\,712\,BS^2 + 313\,344\,B}}$

Memory

Conv1 params = $32 \cdot 3 \cdot 7 \cdot 7 = 4704$ +

Conv2 params = $64 \cdot 32 \cdot 5 \cdot 5 = 51200$ +

Conv3 params = $128 \cdot 64 \cdot 3 \cdot 3 = 73728$ +

Conv4 params = $256 \cdot 128 \cdot 1 \cdot 1 = 32768$ +

Conv5 params = $256 \cdot 256 \cdot 3 \cdot 3 = 589824$ +

Conv6 params = $512 \cdot 256 \cdot 1 \cdot 1 = 131072$

$\underline{\hspace{1cm}} = 883\,296$ total conv params

FC1 params = $\overbrace{512 \cdot 256}^{\text{weights}} + \overbrace{256}^{\text{bias}} = 131\,928$ +

FC2 params = $256 \cdot 100 + 100 = \underline{25700}$

$\underline{\hspace{1cm}} = 157\,028$ total FC params

+ $\underline{1040\,324}$ params

Поскольку FP32 требуется это 4 байта

Unknown: $\underline{\underline{(157028 + 883296) \cdot 4 = 1040324 \cdot 4 = 4,161,296\,B}}$

Peak memory: Наибольшее кол-во памяти требуемое для активации

вызывает после Max pooling:

$$\text{Conv1 output elements} = B \cdot 32 \cdot \frac{S^2}{4} = 8 \cdot B \cdot S^2$$

$$\text{Max pool output elements} = B \cdot 32 \cdot \frac{S^2}{16} = 2 \cdot B \cdot S^2$$

$$\text{Входной тензор} = 3 \cdot B \cdot S^2$$

Итого: Peak memory = params + conv1 output elements +
+ Max pool output elements + Input tensor elements = $(1040324 + 13BS^2) \cdot 4B$

Bytes Moved: Conv/FC: чтение входа, чтение парам-в, запись выхода

ReLU: чтение активации, запись активации

Pooling: чтение входа, запись выхода

График:

$$\text{Все операции} = 16BS^2 + 21BS^2 + 883296$$

$$\text{Все ReLU} = 2 \cdot 21BS^2 + 512B = 42BS^2 + 512B$$

$$\text{Max Pool} = 8BS^2 + 2BS^2 = 10BS^2 \quad \leftarrow \text{после FC}_1$$

Conv1 output Max pool output

$$\text{Global Avg Pool} = B \cdot 512 \cdot \frac{S^2}{16^2} + 512B = 2BS^2 + 512B$$

$$\text{FC}_1: 512B + 256B + 131328 = 768B + 131328$$

$$\text{FC}_2: 256B + 100B + 25700 = 356B + 25700$$

$$\text{Итого moved elements} = 91 \cdot B \cdot S^2 + 2148B + 1040324$$

$$Q = \text{Bytes moved} = 4 \cdot (91BS^2 + 2148B + 1040324)$$

$$\text{Вход операции} = \overset{\text{Conv1}}{3BS^2} + \overset{\text{Conv2}}{2BS^2} + \overset{\text{Conv3}}{4BS^2} + \overset{\text{Conv4}}{2BS^2} + \overset{\text{Conv5}}{4BS^2} + \overset{\text{Conv6}}{BS^2} = 16BS^2$$

$$\text{Выход операции} = \overset{\text{Conv1}}{8BS^2} + \overset{\text{Conv2}}{4BS^2} + \overset{\text{Conv3}}{2BS^2} + \overset{\text{Conv4}}{4BS^2} + \overset{\text{Conv5}}{BS^2} + \overset{\text{Conv6}}{2BS^2} = 21BS^2$$

Latency: Latency имеет 3 компонента:

1. Запуск GPU ядер
2. Вычисления (compute-bound)
3. Передача данных из памяти (memory-bound)

Допустим, что вычисления и доступ к памяти могут идти параллельно

Пусть $F = \text{tot FLOPs} = B \cdot (17.712S^2 + 313.344)$,

$Q = 4 \cdot (91BS^2 + 2148B + 1040324)$

t_0 - fixed overhead на запуск

Поэтому Latency = overhead на запуск + max(время вычислений, время передачи в памяти)

$\text{Latency} = t_0 + \max(F/R_{\text{compute}}, Q/R_{\text{memory}})$, где R_{compute} - скорость вычислений

R_{memory} - пропуск. сп-ть памяти

$\Theta_{\text{latency}} = \{t_0, R_{\text{compute}}, R_{\text{memory}}\}$

Energy: $\text{Energy} = E_0 + \text{compute_energy} + \text{memory_energy}$

Пусть E_0 - фикс. энергия для ~~FLOP в Directx/FLOP~~ forward pass в Directx

e_F - энергия для FLOP в Directx/FLOP

e_Q - энергия для передачи байтов Directx/байт

$\text{Energy}(S, B, \Theta_{\text{energy}}) = E_0 + e_F * F(S, B) + e_Q * Q(S, B)$

$\Theta_{\text{energy}} = \{E_0, e_F, e_Q\}$